

Propositions de Projets

Élèves Ingénieurs – ENSA Khouribga

Zakariyaa ISMAILI
Doctorant en IA Médicale

Année universitaire 2025–2026

Contexte

Ces projets s’inscrivent dans le cadre de ma thèse de doctorat qui porte sur l’utilisation de l’intelligence artificielle pour la génération automatique de comptes rendus médicaux à partir de documents hétérogènes (ordonnances, résultats de laboratoire, imagerie, notes cliniques, etc.).

L’idée est de proposer aux étudiants des projets qui leur permettent de toucher aux techniques de Machine Learning, Deep Learning et NLP, tout en produisant des briques qui pourront être réutilisées dans mon pipeline de recherche. Les trois sujets forment un pipeline logique : d’abord classer les documents, ensuite extraire les informations, et enfin générer du texte.

1 Sujet 1 : Classification automatique de documents médicaux hétérogènes

Objectif

L’objectif est de construire un modèle capable de classer automatiquement un document médical selon sa nature : ordonnance, résultat de labo, imagerie, compte rendu, lettre de liaison, certificat médical, etc. C’est la première étape du pipeline : avant de pouvoir extraire quoi que ce soit, il faut savoir à quel type de document on a affaire.

Côté recherche, ça me donne un classifieur fonctionnel que je peux directement intégrer dans ma thèse. Côté étudiants, c’est un projet de classification classique qui couvre bien le cycle ML/DL.

Techniques

- **ML classique** : TF-IDF + SVM ou Logistic Regression sur le texte extrait par OCR
- **Deep Learning** : CNN (ResNet, EfficientNet, VGG) pour classer les images de documents
- **Transfer Learning** : fine-tuning d’un modèle pré-entraîné sur ImageNet
- **OCR** : Tesseract ou EasyOCR pour extraire le texte des documents scannés

- **Approche multimodale** : fusion des features texte et image pour une meilleure classification

Datasets publics

Dataset	Description	Accès
RVL-CDIP	400k images de documents classés en 16 catégories	HuggingFace
PubLayNet	360k+ images d'articles scientifiques annotés	GitHub (IBM)
Medical MNIST	Images médicales classifiées (radios, dermatos, etc.)	Kaggle
DocBank	500k pages de documents avec annotations de structure	GitHub

Livrables

- Modèle de classification (ML + DL) avec comparaison des performances
- API de classification déployée avec FastAPI
- Rapport technique avec matrice de confusion et analyse des erreurs
- Code source documenté sur GitHub

2 Sujet 2 : Extraction d'entités nommées médicales (NER médical)

Objectif

Ici on cherche à extraire automatiquement les entités clés d'un texte médical : médicaments, dosages, diagnostics, symptômes, organes, résultats d'analyses, procédures. C'est vraiment le cœur du pipeline : on passe du texte brut à de l'information structurée qu'on pourra ensuite utiliser pour générer un compte rendu.

Pour ma thèse, ça me donne un modèle NER médical directement intégrable. Pour les étudiants, c'est une bonne introduction au NLP appliqué avec une progression CRF → BiLSTM → Transformers.

Techniques

- **CRF (Conditional Random Fields)** : approche ML classique pour le sequence labeling avec features manuelles (POS tags, préfixes, gazetteers médicaux)
- **BiLSTM + CRF** : réseau récurrent bidirectionnel combiné avec CRF pour la prédiction de séquences
- **Transformers** : fine-tuning de CamemBERT (français) ou BioBERT (anglais médical) sur une tâche de token classification
- **Annotation** : format BIO (Begin-Inside-Outside) pour l'étiquetage des entités

Datasets publics

Dataset	Description	Accès
n2c2 / i2b2	Notes cliniques en anglais annotées (médicaments, diagnostics)	Harvard DBMI
CADEC	Événements indésirables médicamenteux annotés	CSIRO (open)
BC5CDR	Détection de maladies et produits chimiques	BioCreative
NCBI Disease	Corpus annoté pour la reconnaissance de maladies	NCBI
WikiNER-fr	Corpus NER français basé sur Wikipedia	GitHub
DrBERT / DEFT 2021	Corpus français médical pour NER	deft.limsi.fr

Livrables

- 3 modèles entraînés : CRF, BiLSTM-CRF, Transformer fine-tuné
- Benchmark comparatif des 3 approches avec analyse des erreurs
- Interface de visualisation des entités (type spaCy displaCy)
- Rapport technique et code documenté sur GitHub

3 Sujet 3 : Génération automatique de résumés de documents médicaux

Objectif

Le but est de générer un résumé structuré à partir d'un ou plusieurs textes médicaux : notes cliniques, résultats d'examens, comptes rendus de consultation. C'est en gros une version simplifiée de l'objectif final de ma thèse. Ça permet de commencer à identifier les vrais défis : hallucinations, cohérence du texte généré, fidélité factuelle, spécificités du langage médical.

Pour les étudiants, c'est une introduction concrète à l'IA générative dans un domaine critique, avec du fine-tuning de LLMs et du prompt engineering.

Techniques

- **Approche extractive** : TextRank, BERTScore pour sélectionner les phrases clés
- **Approche abstractive** : fine-tuning de T5, BART ou BioBART sur des paires document/résumé
- **LLM + Prompt Engineering** : utilisation de modèles open-source (Mistral, LLaMA) via Ollama en local
- **RAG (Retrieval-Augmented Generation)** : intégration d'une base de connaissances médicales pour améliorer la fidélité
- **Évaluation** : ROUGE (1, 2, L), BERTScore, évaluation humaine de la fidélité factuelle

Datasets publics

Dataset	Description	Accès
MIMIC-III	Notes cliniques en anglais (soins intensifs)	PhysioNet (gratuit)
MIMIC-IV-Note	Version mise à jour avec notes de décharge	PhysioNet (gratuit)
PubMed	Articles biomédicaux avec abstracts (paires article/résumé)	HuggingFace
CAS	Cas cliniques publiés en français et anglais	NaCTeM
BioASQ	QA biomédicales avec textes de référence	bioasq.org
MS ²	Résumés multi-documents d'études médicales	GitHub (AllenAI)

Livrables

- Pipeline de résumé médical (extractif + abstractif + LLM)
- Benchmark comparatif des 3 approches
- Analyse des hallucinations et erreurs factuelles
- Démo interactive avec Gradio ou Streamlit
- Rapport technique et code source sur GitHub